Технология MapReduce

Даниил Тиуков

Исходный код и результаты: github.com/Zer-o0/datainj.

1. Подготовка данных

Для работы использован it_vacancies_2024.csv, содержащий 229 388 вакансий. Файл загружен в бакет hh-lake объектного хранилища RustFS. Использован RustFS в Docker, развёрнутый в предыдущей работе.

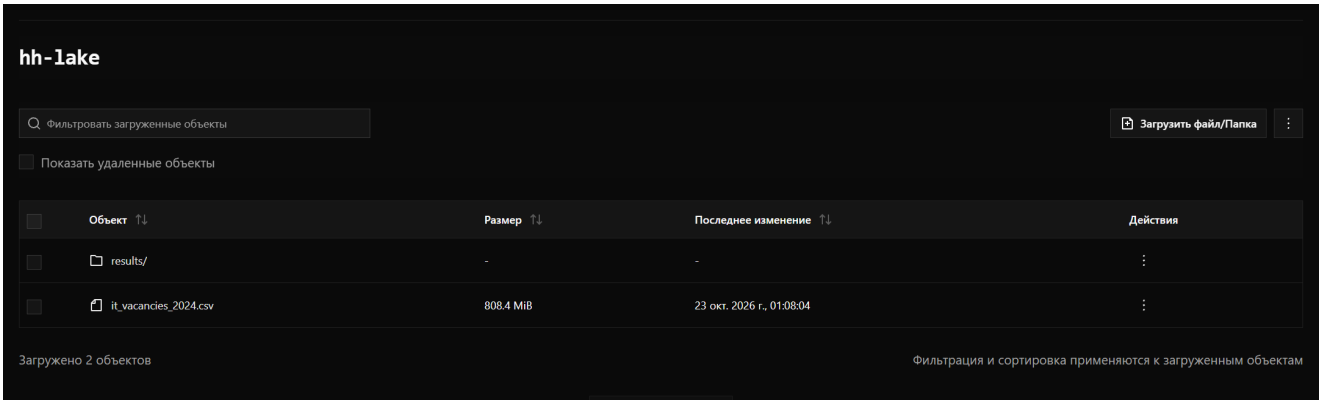


Рисунок 1. Исходный файл в бакете hh-lake.

Отобраны **6 100 вакансий Java** с ролью «Программист, разработчик». Навыки взяты из поля key_skills, приведены к нижнему регистру и очищены от повторов внутри каждой вакансии.

2. Подсчёт навыков

MapReduce. Собственная реализация читает CSV из S3 чанками по 2000 строк. Два mapper-процесса формируют одиночные навыки, пары и тройки, reducer суммирует их частоты.

DuckDB. SQL-запрос независимо читает тот же объект из S3, отбирает вакансии Java и считает навыки и их сочетания. Порядок навыков в паре или тройке не учитывается. Частота равна числу вакансий, содержащих весь набор.

Набор	Различных наборов	Вхождений MapReduce	Вхождений DuckDB
Один навык	1 069	27 086	27 086
Пара	15 755	104 741	104 741
Тройка	103 138	323 377	323 377

3. Проверка и сохранение результатов

Сопоставлены полные словари частот и списки отобранных вакансий. **Результаты MapReduce и DuckDB полностью совпали** во всех запусках.

Вывод программ

MapReduce

```
mapreduce: 6100 Java vacancies
k=1: unique=1069, occurrences=27086
k=2: unique=15755, occurrences=104741
k=3: unique=103138, occurrences=323377
```

DuckDB

```
duckdb: 6100 Java vacancies
k=1: unique=1069, occurrences=27086
k=2: unique=15755, occurrences=104741
k=3: unique=103138, occurrences=323377
```

Количество вхождений растёт: 27 086 для одиночных навыков, 104 741 для пар и 323 377 для троек. Вакансия с m навыками даёт C(m, k) сочетаний. Например, при 10 навыках получаются 10 одиночных навыков, 45 пар и 120 троек. Суммы сочетаний по вакансиям совпали с рассчитанными частотами.

Результаты для всех трёх размеров набора сохранены в hh-lake. На рисунке показаны файлы собственного MapReduce.

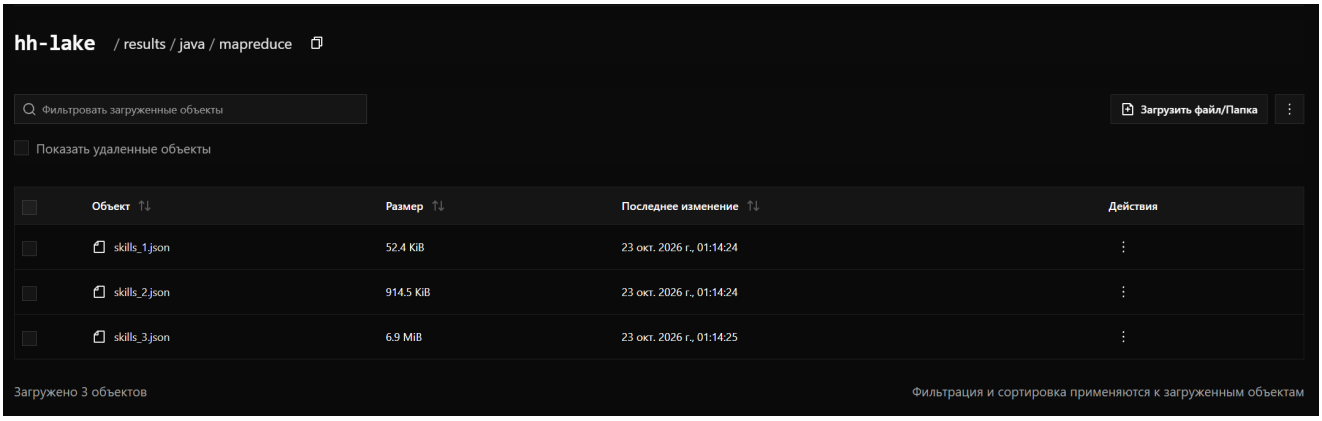


Рисунок 2. Частоты одиночных навыков, пар и троек в RustFS.

Дополнительно проверен отказ mapper: до выдачи результата вызвано исключение, после чего чанк обработан повторно. Reducer учёл его один раз, итоговые частоты не изменились.

4. Сравнение времени и памяти

Для каждого способа выполнено по три запуска на одном компьютере: 16 физических ядер, 15.4 ГиБ RAM. Для вычислений выделено по два потока или процесса. Запуски проводились последовательно с изменением порядка способов.

Способ	Попытка	Время, с	Пик памяти, МиБ
DuckDB	1	17.695	1527.9
DuckDB	2	14.622	1502.5
DuckDB	3	14.501	1492.1
DuckDB после оптимизации	1	12.937	1363.9
DuckDB после оптимизации	2	13.156	1363.1
DuckDB после оптимизации	3	12.539	1363.6
MapReduce	1	27.471	229.1
MapReduce	2	18.263	221.2
MapReduce	3	18.779	207.5

Способ	Медиана времени, с	Медиана пиков памяти, МиБ
MapReduce	18.779	221.2
DuckDB	14.622	1502.5
DuckDB после оптимизации	12.937	1363.6

Время включает запуск Python, чтение из S3, вычисления и запись результата. Память измерялась как сумма RSS основного и mapper-процессов с целевым интервалом 10 мс. Короткие пики могут быть пропущены; память RustFS не учитывалась. Загрузка исходного файла и установка зависимостей выполнены до замеров. Кеши не очищались.

Оптимизация DuckDB

Вместо повторного чтения CSV выбранные вакансии один раз сохраняются во временную таблицу DuckDB. Её создание включено во время расчёта. Результаты после оптимизации полностью совпали с исходными.

Медианное время сократилось с 14.622 до 12.937 с (11.5%). Медиана пиков памяти уменьшилась с 1502.5 до 1363.6 МиБ.

На этом наборе DuckDB быстрее MapReduce, но использует больше памяти. MapReduce тратит время на обработку строк Python и обмен между процессами. DuckDB выполняет запросы векторизованно, а материализация выборки сокращает повторную обработку большого CSV.

5. Зарплаты и пары навыков

Для сравнения взяты рублёвые зарплаты «на руки». При двух границах используется середина вилки, при одной берётся указанная сумма. Пропуски и некорректные значения исключены. Месячный период принят как допущение, поскольку отдельного поля периода в CSV нет.

Сопоставимая зарплата указана в 859 вакансиях. Общая медиана составляет 200 000 руб. В рейтинги включены наборы с пятью и более зарплатными наблюдениями.

Для пары база сравнения содержит более частый из двух навыков. Для тройки базой служит наиболее частая входящая пара. Изменение рассчитано относительно медианы базы: 100 × (медиана набора / медиана базы − 1). Базовая группа включает все вакансии с соответствующим навыком или парой.

Наибольший рост медианы

Набор и база	Частота набор / база	n зарплат набор / база	Медиана набор / база, руб.	Изменение
gradle + microservices; база: gradle	10 / 161	6 / 31	400 000 / 200 000	+100.0%
hibernate orm + rabbitmq; база: hibernate orm	60 / 668	8 / 107	390 000 / 200 000	+95.0%
apache maven + ооп; база: ооп	28 / 535	8 / 55	225 000 / 120 000	+87.5%

Наибольшее снижение медианы

Набор и база	Частота набор / база	n зарплат набор / база	Медиана набор / база, руб.	Изменение
html + typescript; база: html	7 / 116	5 / 27	40 000 / 150 000	-73.3%
git + mockito; база: git	24 / 1045	7 / 230	60 000 / 200 000	-70.0%
git + spring web; база: git	8 / 1045	5 / 230	65 000 / 200 000	-67.5%

Наблюдения

В наборе gradle + microservices 5 из 6 зарплатных вакансий имеют требование «От 3 до 6 лет». В базовой группе таких 23 из 31.

В наборе html + typescript 3 из 5 зарплатных вакансий имеют требование «Нет опыта». В базовой группе таких 5 из 27.

Среди предложений с отрицательным сдвигом больше вакансий для кандидатов без опыта. Это помогает объяснить снижение медианы. Сдвиги характеризуют состав выборки, а не гарантированное изменение оплаты при освоении навыка.

5.1. Зарплаты и тройки навыков

Медиана тройки сравнивается с медианой наиболее частой входящей пары. Используются те же правила отбора зарплат и порог в пять наблюдений.

Наибольший рост медианы

Набор и база	Частота набор / база	n зарплат набор / база	Медиана набор / база, руб.	Изменение
java + solid + ооп; база: java + ооп	13 / 519	5 / 46	270 000 / 102 500	+163.4%
apache maven + java + ооп; база: java + ооп	27 / 519	7 / 46	225 000 / 102 500	+119.5%
apache kafka + rest + soap; база: rest + soap	14 / 97	5 / 25	420 000 / 200 000	+110.0%

Наибольшее снижение медианы

Набор и база	Частота набор / база	n зарплат набор / база	Медиана набор / база, руб.	Изменение
javascript + react + typescript; база: javascript + react	10 / 99	5 / 9	40 000 / 170 000	-76.5%
git + java se + sql; база: git + sql	32 / 447	7 / 114	50 000 / 200 000	-75.0%
postgresql + spring boot + spring web; база: postgresql + spring boot	7 / 513	5 / 102	70 000 / 240 000	-70.8%

Наблюдения

В наборе java + solid + ооп 4 из 5 зарплатных вакансий имеют требование «От 3 до 6 лет». В базовой группе таких 19 из 46.

В наборе javascript + react + typescript 3 из 5 зарплатных вакансий имеют требование «Нет опыта». В базовой группе таких 3 из 9.

Среди предложений с отрицательным сдвигом больше вакансий для кандидатов без опыта. Это помогает объяснить снижение медианы. Сдвиги характеризуют состав выборки, а не гарантированное изменение оплаты при освоении навыка.

6. Сравнение регионов

Выбраны Москва, Санкт-Петербург и Новосибирск. Используется регион публикации вакансии. Общие показатели включают объявления без навыков и без зарплаты.

Регион	Вакансий	Без навыков	n зарплат	Медиана, руб.
Москва	3 030	1 150	417	230 000
Санкт-Петербург	801	286	134	200 000
Новосибирск	271	87	49	185 000

Москва

k	Навыки	Вакансий	n зарплат	Медиана, руб.
1	java	1692	287	250 000
1	spring framework	963	152	250 000
2	java + spring framework	898	145	250 000
2	java + postgresql	714	123	250 000
3	java + postgresql + spring framework	437	77	250 000
3	java + spring framework + sql	283	59	250 000

Санкт-Петербург

k	Навыки	Вакансий	n зарплат	Медиана, руб.
1	java	475	98	210 000
1	spring framework	275	60	240 000
2	java + spring framework	256	52	235 000
2	java + postgresql	212	44	192 500
3	java + postgresql + spring framework	140	27	230 000
3	git + java + spring framework	84	28	200 000

Новосибирск

k	Навыки	Вакансий	n зарплат	Медиана, руб.
1	java	174	38	182 500
1	spring framework	96	18	200 000
2	java + spring framework	94	18	200 000
2	java + postgresql	75	21	200 000
3	java + postgresql + spring framework	49	14	200 000
3	git + java + spring framework	41	12	177 500

Во всех трёх регионах лидируют java и spring framework; наиболее частая тройка состоит из java, postgresql и spring framework. Медиана для этой одинаковой тройки составляет 250 000 руб. в Москве, 230 000 руб. в Санкт-Петербурге и 200 000 руб. в Новосибирске. Значит, даже при совпадении стека регион и состав предложений связаны с различиями в оплате.

Общая медиана Москвы выше новосибирской на 45 000 руб. При этом зарплатных наблюдений в Москве 417, а в Новосибирске 49. Сравнение относится к опубликованным предложениям, а не ко всем работникам этих городов.